

■  
미래기술마당 개선 프로젝트

공공빅데이터 일경험 수련생

# 분석 결과 보고서

## 03: 자연어처리 기반 특허 기술 분류

기관명 과학기술일자리진흥원  
수행기간 2023년 01월 ~ 2023년 02월  
수련생 김인수 황양하



NIA 한국지능정보사회진흥원



# 목차

S-BERT기반 수요기술 매칭 서비스

01

## 프로젝트 개요

전체 프로젝트 개요

— 04

02

## 분석 배경

미래유망신기술이란? — 07

목적 및 근거 — 09

03

## 모델 프로세스

프로젝트 개요

— 07

모델 프로세스

— 09

최종 모델

— 09

04

## 결과와 보완점

프로젝트 결과

— 07

프로젝트 의의

— 09

01

## 프로젝트 개요

전체프로젝트 개요

## 미래기술마당 **서비스 개선**을 위한 프로젝트 진행

프로젝트 1:  
**S-BERT 기반 수요기술 매칭 서비스**

수요자가 신청한 수요기술의 내용을  
기반으로 유사한 특허를 찾아내어  
수요자에게 유사 특허 리스트를 제공

프로젝트 2:  
**BI 기반 통계서비스**

미래기술마당 관리자 통계 화면의  
문제점을 개선하고, 사용자를 위한  
검색어 통계 시각화 서비스를 제공

프로젝트 3:  
**자연어 처리 기반 특허기술 분류**

자연어 처리 기술을 활용하여  
특허 데이터를 미래유망기술(6T)  
분류 기준으로 분류하는 모델을 제작

## 프로젝트 진행 과정



02

## 분석 배경

---

미래유망신기술이란?  
목적 및 근거

**PROBLEM**

내가 찾은 특허,  
**미래유망신기술** 분류별로  
나누어 볼 순 없을까?



앞서 진행했던 프로젝트인 수요기술 매칭 서비스의 결과를 사용자에게 효과적으로 보여주기 위해  
**자연어 처리** 기술을 이용하여 특허를 미래유망신기술 분류별로 나누어 보고자함.

# 미래유망신기술이란?

미래유망신기술(6T)이란 인류의 미래를 주도할 첨단 산업기술로서 주목받고 있는 6가지의 기술을 말한다.



정보기술

IT



생명공학기술

BT



나노기술

NT



환경공학기술

ET



우주항공기술

ST



문화콘텐츠기술

CT

• 기업수요	
도입희망 기술명	반려동물 문진데이터 분석을 활용한 질병 진단 AI 기술
기술분류	정보기술(IT)
기술소개 개요	반려동물을 문진데이터와 검진데이터를 분석하여 질병 진단 판정 AI 기술
기술사업화 지원의향	<input checked="" type="checkbox"/> 대학, 공공연구기관과의 기술이전 공동 R&D 연계 및 지원 <input type="checkbox"/> 연구소기업 설립지원 * 공공연구기관(대학포함)이 기술을 출자하고 기업은 자본을 출자하여 특구(대전, 광주, 대구, 부산) <input checked="" type="checkbox"/> 성장전략 컨설팅(기술/시장/재무분석, 마케팅, 사업파트너 발굴, IR 등) <input type="checkbox"/> 투자유치(투·융자 연계 등) <input type="checkbox"/> 기타(창업/기업 간 기술협력, 합작법인, M&A 등)
기술거래유형	<input checked="" type="checkbox"/> 기술매매 <input checked="" type="checkbox"/> 라이센스 <input checked="" type="checkbox"/> 기술협력 <input checked="" type="checkbox"/> 기술지도 <input checked="" type="checkbox"/> M&A <input type="checkbox"/> 공동연구개발

수요기술 신청은 6T 분류 기준으로 신청하지만  
추천 특허들은 6T 기준으로 분류되어 있지 않아  
사용자들이 6T 기준으로 특허를 볼 수 없는 불편함이 있음.

특허를 6T 기준으로 분류하여 사용자에게 제공하고자 함.

03

## 모델 프로세스

---

프로젝트 개요

모델 프로세스

최종 모델

### DATA 프로젝트 활용 데이터

데이터

NTIS사업 과제 정보

KIPRIS특허 서지정보

건수

451,070건

1,588,185건

### TOOL 프로젝트에서 사용한 툴




PostgreSQL



## 미래유망기술 분류 **프로세스**

특허를 6T 기준으로 분류하여 기술 수요자들의 편의성을 향상시키고자 함.



## PROCESS 01: 데이터 전처리

### NTIS 국가과제 정보 데이터의 '초록'과 Target 데이터인 '6T분류' 데이터 정제


```
df.abstractfullteaser.iloc[0]
'▶ 전면적/선택적 나노표면 구현을 위한 나노 금형 인서트 제작기술 \n\n- 나노 금형 인서트 설계: 나노 제작공정의 한계를 고려한 금형설계\n\n- 나노 금형 인서트 제작: (1) 양극산화 알루미늄 공정과 폴리아이드 리소그래피 공정을 융용한 나노구조 템플릿 제작, (2) 니켈 나노전주도금을 이용한 고내구성 나노 금형 인서트 제작\n\n- 나노 금형 인서트 평가: 제작된 나노 금형 인서트에 대한 기계적 특성 평가\n▶ 나노표면 대량생산을 위한 성형기술\n\n- 나노표면 성형공정모사: 컴퓨터 모사기술을 통한 나노표면 공정변수 도출 및 공정 최적화\n\n- 나노표면 성형공정기술: 나노사출/압축성형, 나노엠보싱공정을 기반으로 나노표면의 제작 및 대량생산 가능성 확인\n\n- 나노표면 성형공정 평가: 제작된 나노표면의 성형성 평가 및 화학적/물리적 특성 평가\n▶ 세포외기질 단백질의 미세패턴 전사기술\n\n- 단백질 미세패턴 표면 설계: 미세 제작공정의 한계를 고려한 양성 스템프 및 스템실 설계\n\n- 단백질 미세패턴 표면 제작: (1) 마이크로 콘택트 프린팅 공정과 (2) 스템실 공정을 융용한 단백질 미세패턴 표면의 제작\n\n- 단백질 미세패턴 표면의 화학적/물리적 특성 평가\n▶ 나노표면과 단백질 미세패턴 표면을 이용한 단일줄기세포 기종제어\n\n- 세포외기질 단백질 미세패턴에 의한 단일줄기세포 기종제어 연구 (화학적 요인)\n\n- 전면적/선택적 나노표면에 의한 단일줄기세포 기종제어 연구 (물리적 요인)\n\n- 단일줄기세포 기종제어용 선택적 나노표면 세포배양조 대량생산 기술 확보\n\n- 세포배양조 설계: 기종제어 연구를 통해 도출된 결과를 바탕으로 세포배양조를 설계\n\n- 세포배양조 제작: (1) 성형공정 기술을 고려한 세포배양조 금형설계, (2) 컴퓨터 모사기술을 통한 공정변수 도출 및 공정 최적화, (3) 성형공정 최적화를 통한 대량 생산 기술 확보\n\n- 세포배양조 평가: 제작된 세포배양조의 화학적/물리적 특성평가'
```

BT(생명공학기술)	180580
위의 미래유망신기술(6T) 103개 세분류에 속하지 않는 기타 연구	88205
IT(정보기술)	77866
ET(환경기술)	62157
NT(나노기술)	32578
CT(문화기술)	6930
ST(우주항공기술)	5041

- 괄호와괄호안에있는문자제거
- 모든영문자는소문자로변경
- 특수문자와한칸이상의공백제거
- HTML태그제거
- 숫자넘버링(로마자,영어)제거
- 중복데이터와빈열제거

- Label데이터의특수문자제거
- 괄호와괄호안문자제거
- Label중기타에해당하는분류는성능과 관련없는데이터로간주해훈련과평가 데이터에서제외

## PROCESS 01: 데이터 전처리



Train 데이터의 Target 분포를 확인해 본 결과,  
데이터의 불균형이 매우 심한 것을 확인할 수 있었음.

불균형 데이터 레이블의 균형을 맞춰주기 위해  
**Text Data Augmentation**을 진행함.

### Synonym Replacement

특정 단어를 유의어로  
교체하는 방식

### Random Deletion


임의의 단어를 삭제하는 방식

### Random Insertion

임의의 단어를 삽입하는 방식

### Random Swap

문장 내 임의의 단어의  
위치를 바꾸는 방식



대표적인 4가지 텍스트 데이터 증강 기법 중  
적용이 권장되는 방법은 RD와 RS.  
둘 중 데이터와 문맥의 손실이 적다고 판단되는  
**Random Swap** 방법을 사용하여 데이터를 증강시킴.  
증강 후 가장 많은 데이터를 기준으로 샘플링 함.


데이터 증강 전에 비해 Target 값의 불균형이  
많이 해소된 것을 볼 수 있음.  
모델 학습 시에는 **증강 전과 후 데이터에**  
**모두 학습**하여 그 성능을 비교 함.

**PROCESS 02:** 모델 학습 - LSTM

데이터의 형식을 LSTM의 학습에 적합하도록 수정해 줌.

문장 샘플들을 신경망 모델의 Input이 될 수 있도록 문장을 **토큰화** 한 후, **정수 시퀀스**로 만들어 주어야 함.

Mecab에 KoPatElectra의 사용자단어 사전을 추가하여 만든 토크나이저로 문장을 토큰화시켜 전처리함.




## PROCESS 02: 모델 학습 - LSTM

단어 집합(vocabulary)의 크기 : 345120  
 등장 빈도가 2번 미하인 희귀 단어의 수: 213442  
 단어 집합에서 희귀 단어의 비율: 61.845734816875286  
 전체 등장 빈도에서 희귀 단어 등장 빈도 비율: 2.804399131304  
 단어 집합의 크기 : 131679

**빈도수가 낮은 단어는 훈련 데이터에서 제외하기 위해 등장 빈도수가 2회 이하인 희귀 단어들의 분포를 확인.**  
 희귀 단어들은 전체 데이터에서 284%를 차지하고 있음  
 모델 훈련 과정에서 중요하지 않다고 판단하여 제외.  
 희귀 단어 제외로 인해 값이 없어진 샘플들은 삭제.

Keras의 tokenizer를 통해  
**텍스트 시퀀스를 정수 시퀀스로 변환**

text의 최대 길이 : 275  
 text의 평균 길이 : 56.9610208873603



전체 샘플 중 길이가 150 미하인 샘플의 비율: 98.37

정수 시퀀스로 변환된 샘플들의 서로 다른 길이를 동일하게 맞춰 줌.  
 전체 데이터 길이의 분포를 파악한 후,  
 전체 훈련 데이터의 98%를 반영하는 150으로  
**모든 데이터의 길이를 통일**

**PROCESS 02:** 모델 학습 - LSTM

다중분류 학습에 적합하게 LSTM모델의 하이퍼 파라미터를 조정함

```
embedding_dim = 256
hidden_units = 256
num_classes = 6

model = Sequential()
model.add(Embedding(vocab_size, embedding_dim, input_length=150))
model.add(LSTM(hidden_units, activation = 'relu', return_sequences = False))
model.add(Dense(num_classes, activation='softmax'))

es = EarlyStopping(monitor='val_loss', mode='auto', verbose=1, patience=7)
mc = ModelCheckpoint('bm_ntis_lstm0222.h5', monitor='val_acc', mode='max', verbose=1, save_best_only=True)

model.compile(loss='categorical_crossentropy', optimizer=tf.keras.optimizers.RMSprop(learning_rate=0.0001), metrics=['acc'])
history = model.fit(X_tr, y_tr, batch_size=1000, epochs=20, callbacks=[es, mc], validation_data=(X_val, y_val)) #validation_split=0.2
```

활성화 함수	Sigmoid
Loss function	Categorical crossentropy
Optimizer	RMSprop
Batch size	1000

## PROCESS 02: 모델 학습 - LSTM

	precision	recall	f1-score	support
0	0.86	0.92	0.89	36116
1	0.56	0.54	0.55	1386
2	0.79	0.78	0.78	12432
3	0.82	0.85	0.83	15572
4	0.69	0.54	0.61	6516
5	0.75	0.61	0.67	1008
accuracy			0.81	73030
macro avg	0.75	0.71	0.72	73030
weighted avg	0.80	0.81	0.80	73030

데이터 불균형 해소를 위해 **데이터를 증강**하여 학습시킨  
모델 성능을 평가해 본 결과  
Accuracy는 0.81, Macro F1 Score는 0.72으로  
전체적으로 준수한 성능을 보임.

	precision	recall	f1-score	support
0	0.89	0.92	0.90	23546
1	0.00	0.00	0.00	1098
2	0.48	0.64	0.55	9578
3	0.66	0.79	0.72	11766
4	0.00	0.00	0.00	4333
5	0.00	0.00	0.00	654
accuracy			0.73	50975
macro avg	0.34	0.39	0.36	50975
weighted avg	0.65	0.73	0.69	50975

데이터를 **증강하지 않고** 학습을 진행한  
모델 성능을 평가해 본 결과  
Accuracy는 0.73, Macro F1 Score는 0.36으로  
특정 클래스의 결과만 잘 측정하는 모델임.

## PROCESS 02: 모델 학습 - Fasttext

sixtechnologylarge	abstractfullteaser
NT(나노기술)	▶ 전면적/선택적 나노표면 구현을 위한 나노 금형 인서트 제작기술 \n\n- 나...
NT(나노기술)	본 연구에서는 연구책임자가 기개발한 그래핀 제조법들을 이용하여 초고도 소수성과 우수...
BT(생명공학기술)	1. 두경부암 세포주 및 환자에서 PAK의 기능 및 역할 규명\n\n...
BT(생명공학기술)	본 연구 과제의 최종 목표는 기능성 나노 프로브와 마이크로 패터닝 기술을 이용하여 ...

↓	
---	--

label	sentence
_label_NT	전면적선택적 나노표면 구현을 위한 나노 금형 인서트 제작기술 나노 금형 인서트 설...
_label_NT	본 연구에서는 연구책임자가 기개발한 그래핀 제조법들을 이용하여 초고도 소수성과 우수...
_label_BT	두경부암 세포주 및 환자에서 pak의 기능 및 역할 규명 두경부암 세포주에서 pa...
_label_BT	본 연구 과제의 최종 목표는 기능성 나노 프로브와 마이크로 패터닝 기술을 이용하여 ...

데이터의 형식을 FastText의  
지도 학습에 적합하도록 수정해 줌.

FastText의 레이블은 \_label\_ 로 시작함.  
데이터의 클래스 앞에 \_label\_ 을 붙여주어  
학습이 가능한 형식으로 만들어 줌.

## PROCESS 02: 모델 학습 - Fasttext

```
model = fasttext.train_supervised(input='train_dataset.txt',
                                   autotuneValidationFile='ntis_test.txt',
                                   autotuneMetric="f1:_label__CT")
```

Train 데이터로 지도 학습을 수행함.  
Auto Tuner를 이용하여  
하이퍼 파라미터를 자동 조정 해주었음.  
선행분석에서 F1-Score가 가장 낮았던 CT의 F1-Score가  
가장 높을 때의 모델을 선정하는 것으로 설정함.

	precision	recall	f1-score	support
BT	0.94	0.92	0.93	23594
CT	0.54	0.60	0.57	1127
ET	0.80	0.78	0.79	9622
IT	0.80	0.84	0.82	11820
NT	0.71	0.73	0.72	4379
ST	0.70	0.66	0.68	661
accuracy			0.85	51203
macro avg	0.75	0.76	0.75	51203
weighted avg	0.85	0.85	0.85	51203

데이터 불균형 해소를 위해 **데이터를 증강**하여 학습시킨  
모델 성능을 평가해 본 결과  
Accuracy는 0.85, Macro F1 Score는 0.75으로  
전체적으로 준수한 성능을 보임.

**PROCESS 02:** 모델 학습 - Fasttext

```
model = fasttext.train_supervised(input='train_dataset.txt',
                                   autotuneValidationFile='ntis_test.txt',
                                   autotuneMetric="f1:__label__CT")
```

Train 데이터로 지도 학습을 수행함.  
Auto Tuner를 이용하여  
하이퍼 파라미터를 자동 조정 해주었음.  
선행분석에서 F1-Score가 가장 낮았던 CT의 F1-Score가  
가장 높을 때의 모델을 선정하는 것으로 설정함.

	precision	recall	f1-score	support
BT	0.95	0.96	0.96	36116
CT	0.81	0.57	0.67	1386
ET	0.86	0.85	0.85	12432
IT	0.85	0.90	0.87	15572
NT	0.88	0.81	0.84	6516
ST	0.87	0.68	0.77	1008
accuracy			0.90	73030
macro avg	0.87	0.80	0.83	73030
weighted avg	0.90	0.90	0.90	73030

데이터를 증강하지 않고 학습을 진행한  
모델 성능을 평가해 본 결과  
Accuracy는 0.90, Macro F1 Score는 0.83으로  
증강한 데이터에서 학습했을 때보다 좋은 성능을 보임.

## PROCESS 03: 성능 평가

	LSTM		Fasttext	
	증강 전	증강 후	증강 전	증강 후
Accuracy	0.73	0.81	<b>0.90</b>	0.85
Marco F1-Score	0.36	0.72	<b>0.83</b>	0.75

최종적으로 학습시킨 모든 모델의 성능을 평가해본 결과,  
Accuracy와 Marco F1- Score에서 모두 가장 우수한 성능을 보인  
증강하기 전 데이터로 학습한 **Fasttext모델**을 최종 모델로 선정함.

선택된 최종 모델을 특허 서지정보에 적용하여 **6T분류를 예측해 본 결과**  
아래와 같이 **객관적이고 신뢰성** 있는 분류가 가능함을 확인 할 수 있었음.

## 특허1

**이물질 제거 가능한 펌프를 구비하는 수처리장치**

이물질 제거가 가능한 오·폐수를 정화하기 위한 수처리장치에 관한 특허

## 해당 특허의 IPC 분류

C02 물, 폐수, 하수 또는 오니의 처리  
F04 액체용 용작형 기계  
B01 파쇄, 분쇄 또는 미분쇄

## 예측한 6T 분류



IPC분류와 특허 초록의 내용을 고려했을 때  
수질 오염 처리 및 재이용기술을 포함하는  
ET에 잘 분류된 것을 확인할 수 있음.



## 특허2

**스마트 기기를 이용한 근거리 무선통신 기반 커피 프린팅 서비스 시스템**  
애플리케이션을 통해 서버에 프린팅 이미지를 송신하는 시스템에 관한 특허

## 해당 특허의 IPC 분류

G06 전산  
A23 식품 또는 음료품  
H04 전기통신기술

## 예측한 6T 분류



IPC분류와 특허 초록의 내용을 고려했을 때  
전기통신기술을 포함하는  
IT에 잘 분류된 것을 확인할 수 있음.



04

## 프로젝트 결과

---

프로젝트 결과

프로젝트 의의

특허명 six		
차량 도어 충돌방지 장치	ET	
복수의 전동기를 제어하기 위한 제어장치	ET	
양변기용 쾌변유도형 시트	ET	
플라스테릭 액정을 포함하는 액정 캡슐 및 이의 제조방법	IT	
차량에 구비된 차량 제어 장치 및 그의 제어 방법	IT	
스마트 기기를 이용한 근거리 무선 통신 기반 커피 프린팅 서비스 시스템	IT	
이물질 제거 가능한 펌프를 구비하는 수처리장치	ET	
고이송 편면형 절삭 인서트 및 이를 장착한 절삭 공구	ST	
송풍장치	ET	
멸치 선별기	ET	



기관에 기존재했던 특허 데이터 중,  
등록/공개된 특허 데이터를 모두 6T 기준으로  
분류하여 **새로운 데이터**를 만듦

첫번째 **프로젝트**였던  
'유사 특허 추천 서비스'의 과정에 적용하여  
특허 추천 결과를 6T 기준으로  
**시각화**하여 서비스함.

### 의의 1: 객관적 기준 제공



특허를 객관적인 증거 기반으로 분류하여  
국가 연구개발 사업 성과 활용의 근거로 활용.  
또한 미래유망기술 발굴 및 사업화에 도움.

### 의의 2: 성과조사의 기준



관련 데이터의 연계를 통해  
국가 연구개발 사업 진행 현황에 대한  
효율적이고 체계적인 연구성과 조사 기준 제공

# 부록

## 참고문헌

딥 러닝을 이용한 자연어 처리 입문. (2022.10.25). URL: <https://wikidocs.net/book/2155>

Fasttext 공식 문서. (2023. 01. 20). URL: <https://fasttext.cc/>

# 감사합니다